


# **Бази даних**

## **Лекція 8**

---

# Тематика лекції



Індекси

# Індекс

---

**Індекси це інструмент для покращення швидкодії SELECT запитів.**

**Індекс - окрема структура даних, що зберігає копії проіндексованих даних у організованій формі та містить посилання на відповідні повні рядки оригінальної таблиці.**

# Типи ІНДЕКСІВ

---

- B-Tree index - найбільш розповсюджений тип індексів. Використовується для порівняння ідентичності (=), порівняльних запитів (>, <, BETWEEN), сортування, пошуку за префіксом.
- Hash index - використовується лише для порівняння ідентичності (=), проте швидший ніж B-Tree.
- Вузькоспеціалізовані типи (GiST, GIN, etc).

# Створення Індекса

---

```
CREATE INDEX idx_active_courses_by_name  
ON course(name)  
WHERE is_active = true;
```

# Часткові індекси

---

- Часткові індекси індексують лише частину рядочків таблиці - лише ті рядочки, які задовольняють предикат у WHERE частині індексу.
- Часткові індекси споживають менше пам'яті.
- Трохи більш ефективні ніж повні індекси по швидкодії.

# Часткові індекси

---

```
CREATE INDEX idx_active_courses_by_name  
ON course(name)  
WHERE is_active = true;
```

```
SELECT * FROM course WHERE name = 'Бази даних'; -- ← запит НЕ використає індекс
```

```
SELECT * FROM course WHERE name = 'Бази даних' AND is_active = true; -- ← використає
```

# Композитні індекси

---

CREATE INDEX idx\_some\_name ON some\_table(col1, col2, col3);

Даний індекс ефективний для запитів:

SELECT \* FROM some\_table WHERE col1 = ?

SELECT \* FROM some\_table WHERE col1 = ? AND col2 = ?

SELECT \* FROM some\_table WHERE col1 = ? AND col2 = ? AND col3 = ?

І НЕ ефективний для запитів:

SELECT \* FROM some\_table WHERE col2 = ?

SELECT \* FROM some\_table WHERE col3 = ?



# Композитні індекси

---

Оптимальний порядок колонок в композитному індексі:

- Колонки, по яким йде пошук за ідентичністю попереду.
- Колонки, по яким йде пошук за порівняннями останні.
- Колонки з більшою кардинальністю попереду.

# Переваги ІНДЕКСІВ

---

**Підвищення швидкодії запитів для таблиць, що містять багато даних.**

# Недоліки ІНДЕКСІВ

---

- Споживають доволі багато пам'яті.
- Сповільнюють записи нових рядків в таблицю.
- В певних випадках сповільнюють оновлення та видалення рядків з таблиці.

# Коли індекси шкідливі

---

- Коли відбувається багато записів в таблицю (write-heavy workload).
- Коли багато оновлень проіндексованих колонок.
- Коли кардинальність проіндексованої колонки низька - зазвичай планувальник PostgreSQL сам вирішує не використовувати індекс в запитах у такому випадку.

# Write-Heavy Workload

---

При записі відбувається:

1. Запис даних в таблицю
2. Оновлення індексу первинного ключа (PRIMARY KEY index)
3. Оновлення всіх інших індексів

Таким чином, кожен INSERT перетворюється у 3+ записи на диск, якщо на таблиці є хоч один індекс (окрім PK).

# Оновлення проіндексованої колонки

---

При оновленні проіндексованої колонки **в PostgreSQL** відбувається:

1. Створюється нова версія рядочку (механізм MVCC).
2. В індексі попередня версія рядочку помічається мертвою (dead tuple)
3. В індекс вставляється нова версія

Таким чином, кожен UPDATE перетворюється у 3+ записи на диск.

Також відбувається роздування індексу (index bloat) через те, що стара версія значення оновленої колонки з індексу не видаляється, а лише помічається видаленою. З index bloat Postgres справляється у фоновому режимі за допомогою AUTOVACUUM процесу.

# Колонки низької кардинальності

---

Якщо використовується індекс для колонки з низькою кардинальністю:

1. В індексі знаходяться всі посилання на дані за фільтром.
2. Для кожного посилання відбувається читання даних з таблиці (random I/O).

Якщо НЕ використовується індекс для колонки з низькою кардинальністю:

1. Відбувається послідовне читання всіх даних з таблиці (sequential I/O).
2. Фільтрація відбувається під час читання.

Sequential I/O завжди швидше ніж random I/O і якщо індекс зменшує об'єм даних, які читаються з таблиці менш ніж в ~8-10 разів - Seq Scan таблиці ефективніший.

# Як зрозуміти чому запит повільний

---

**EXPLAIN** SELECT \* FROM course WHERE name = 'Бази даних';

**EXPLAIN ANALYZE** SELECT \* FROM course WHERE name = 'Бази даних';



# План запиту

5	
6	EXPLAIN ANALYZE
7	select c.name, pc.name as prerequisite from course c
8	left join course_prerequisite p on c.course_id = p.course_id
9	left join course pc ON p.prerequisite_course_id = pc.course_id;
10	
Data Output Messages Notifications	
<div><div><div>≡+</div><div>📄</div><div>▼</div><div>📋</div><div>▼</div><div>🗑</div><div>🗄</div><div>⬇</div><div>📈</div><div>SQL</div></div></div>	
	<div>QUERY PLAN</div> <div>text</div> <div>🔒</div>
1	Hash Left Join (cost=2.54..47.25 rows=2260 width=62) (actual time=1.253..1.272 rows=13 loops=1)
2	Hash Cond: (p.prerequisite_course_id = pc.course_id)
3	-> Hash Right Join (cost=1.27..39.92 rows=2260 width=35) (actual time=0.993..1.010 rows=13 loops=1)
4	Hash Cond: (p.course_id = c.course_id)
5	-> Seq Scan on course_prerequisite p (cost=0.00..32.60 rows=2260 width=8) (actual time=0.560..0.568 rows=7 loo...
6	-> Hash (cost=1.12..1.12 rows=12 width=35) (actual time=0.066..0.067 rows=12 loops=1)
7	Buckets: 1024 Batches: 1 Memory Usage: 9kB
8	-> Seq Scan on course c (cost=0.00..1.12 rows=12 width=35) (actual time=0.036..0.038 rows=12 loops=1)
9	-> Hash (cost=1.12..1.12 rows=12 width=35) (actual time=0.020..0.020 rows=12 loops=1)
10	Buckets: 1024 Batches: 1 Memory Usage: 9kB
11	-> Seq Scan on course pc (cost=0.00..1.12 rows=12 width=35) (actual time=0.007..0.008 rows=12 loops=1)
12	Planning Time: 2.949 ms
13	Execution Time: 1.727 ms

# Як зрозуміти план запиту

---

- **Seq Scan** - читання всіх даних в таблиці. Це швидко для невеличких таблиць і дуже повільно для великих.
- **Index Scan** - пошук по індексу та читання рядків з основної таблиці, на які вказує індекс.
- **Index Only Scan** - читання лише з індексу. Це найкращий варіант для великих таблиць. Використовується лише тоді, коли всі дані для запити знаходяться в індексі.
- **Bitmap Index Scan** - читання з кількох індексів.

# ПРАКТИЧНІ ПОРАДИ ВИКОРИСТАННЯ ІНДЕКСІВ

---

- Треба створювати індекси коли швидкодія SELECT запитів є критичною.
- Варто додавати індекси до FOREIGN KEY.
- Варто додавати індекси до колонок, що активно використовуються в WHERE, JOIN, ORDER BY.
- Варто використовувати часткові індекси для предикатів, які часто використовуються в запитах (наприклад “is\_active = true” для soft deletion).

# ПРАКТИЧНІ ПОРАДИ ВИКОРИСТАННЯ ІНДЕКСІВ

---

- Треба відноситись до індексів з розумом - не можна індексувати всі колонки “про всяк випадок”.
- Не варто створювати зайві індекси. До прикладу якщо є `idx(a, b, c)`, то індекс `idx(a, b)` чи `idx(a)` є надлишковими та зайвими.
- Варто обережно відноситись до індексування колонок, які часто змінюються (багато UPDATE).
- Треба не забувати про моніторинг індексів та запитів.

# ПРАКТИЧНІ ПОРАДИ ВИКОРИСТАННЯ ІНДЕКСІВ

---


- Не варто індексувати колонки з низькою варіативністю запитів (наприклад `idx on course(is_active)` - це погана ідея).
- Не варто створювати індекси для запитів, що повертають велику частину даних таблиці (> 15-20% рядків).
- Не варто використовувати “`SELECT *`”, адже це унеможлиблює використання планувальником `Index Only Scan`.

# **ПРАКТИЧНІ ПОРАДИ ВИКОРИСТАННЯ ІНДЕКСІВ**

---

**Потрібно перевіряти запит за допомогою EXPLAIN ANALYZE до та після додавання індексів. Якщо індекс не використовується або не робить запит швидшим - його варто прибрати.**

# B-Tree



## Index Leaf Nodes (sorted)

column 2  
ROWID

11	3C AF
13	F3 91
18	6F B2

21	2C 50
27	0F 1B
27	52 55

34	0D 1E
35	44 53
39	24 5D

## Table (not sorted)

column 1  
column 2  
column 3  
column 4

A	34	1	2
A	27	5	9

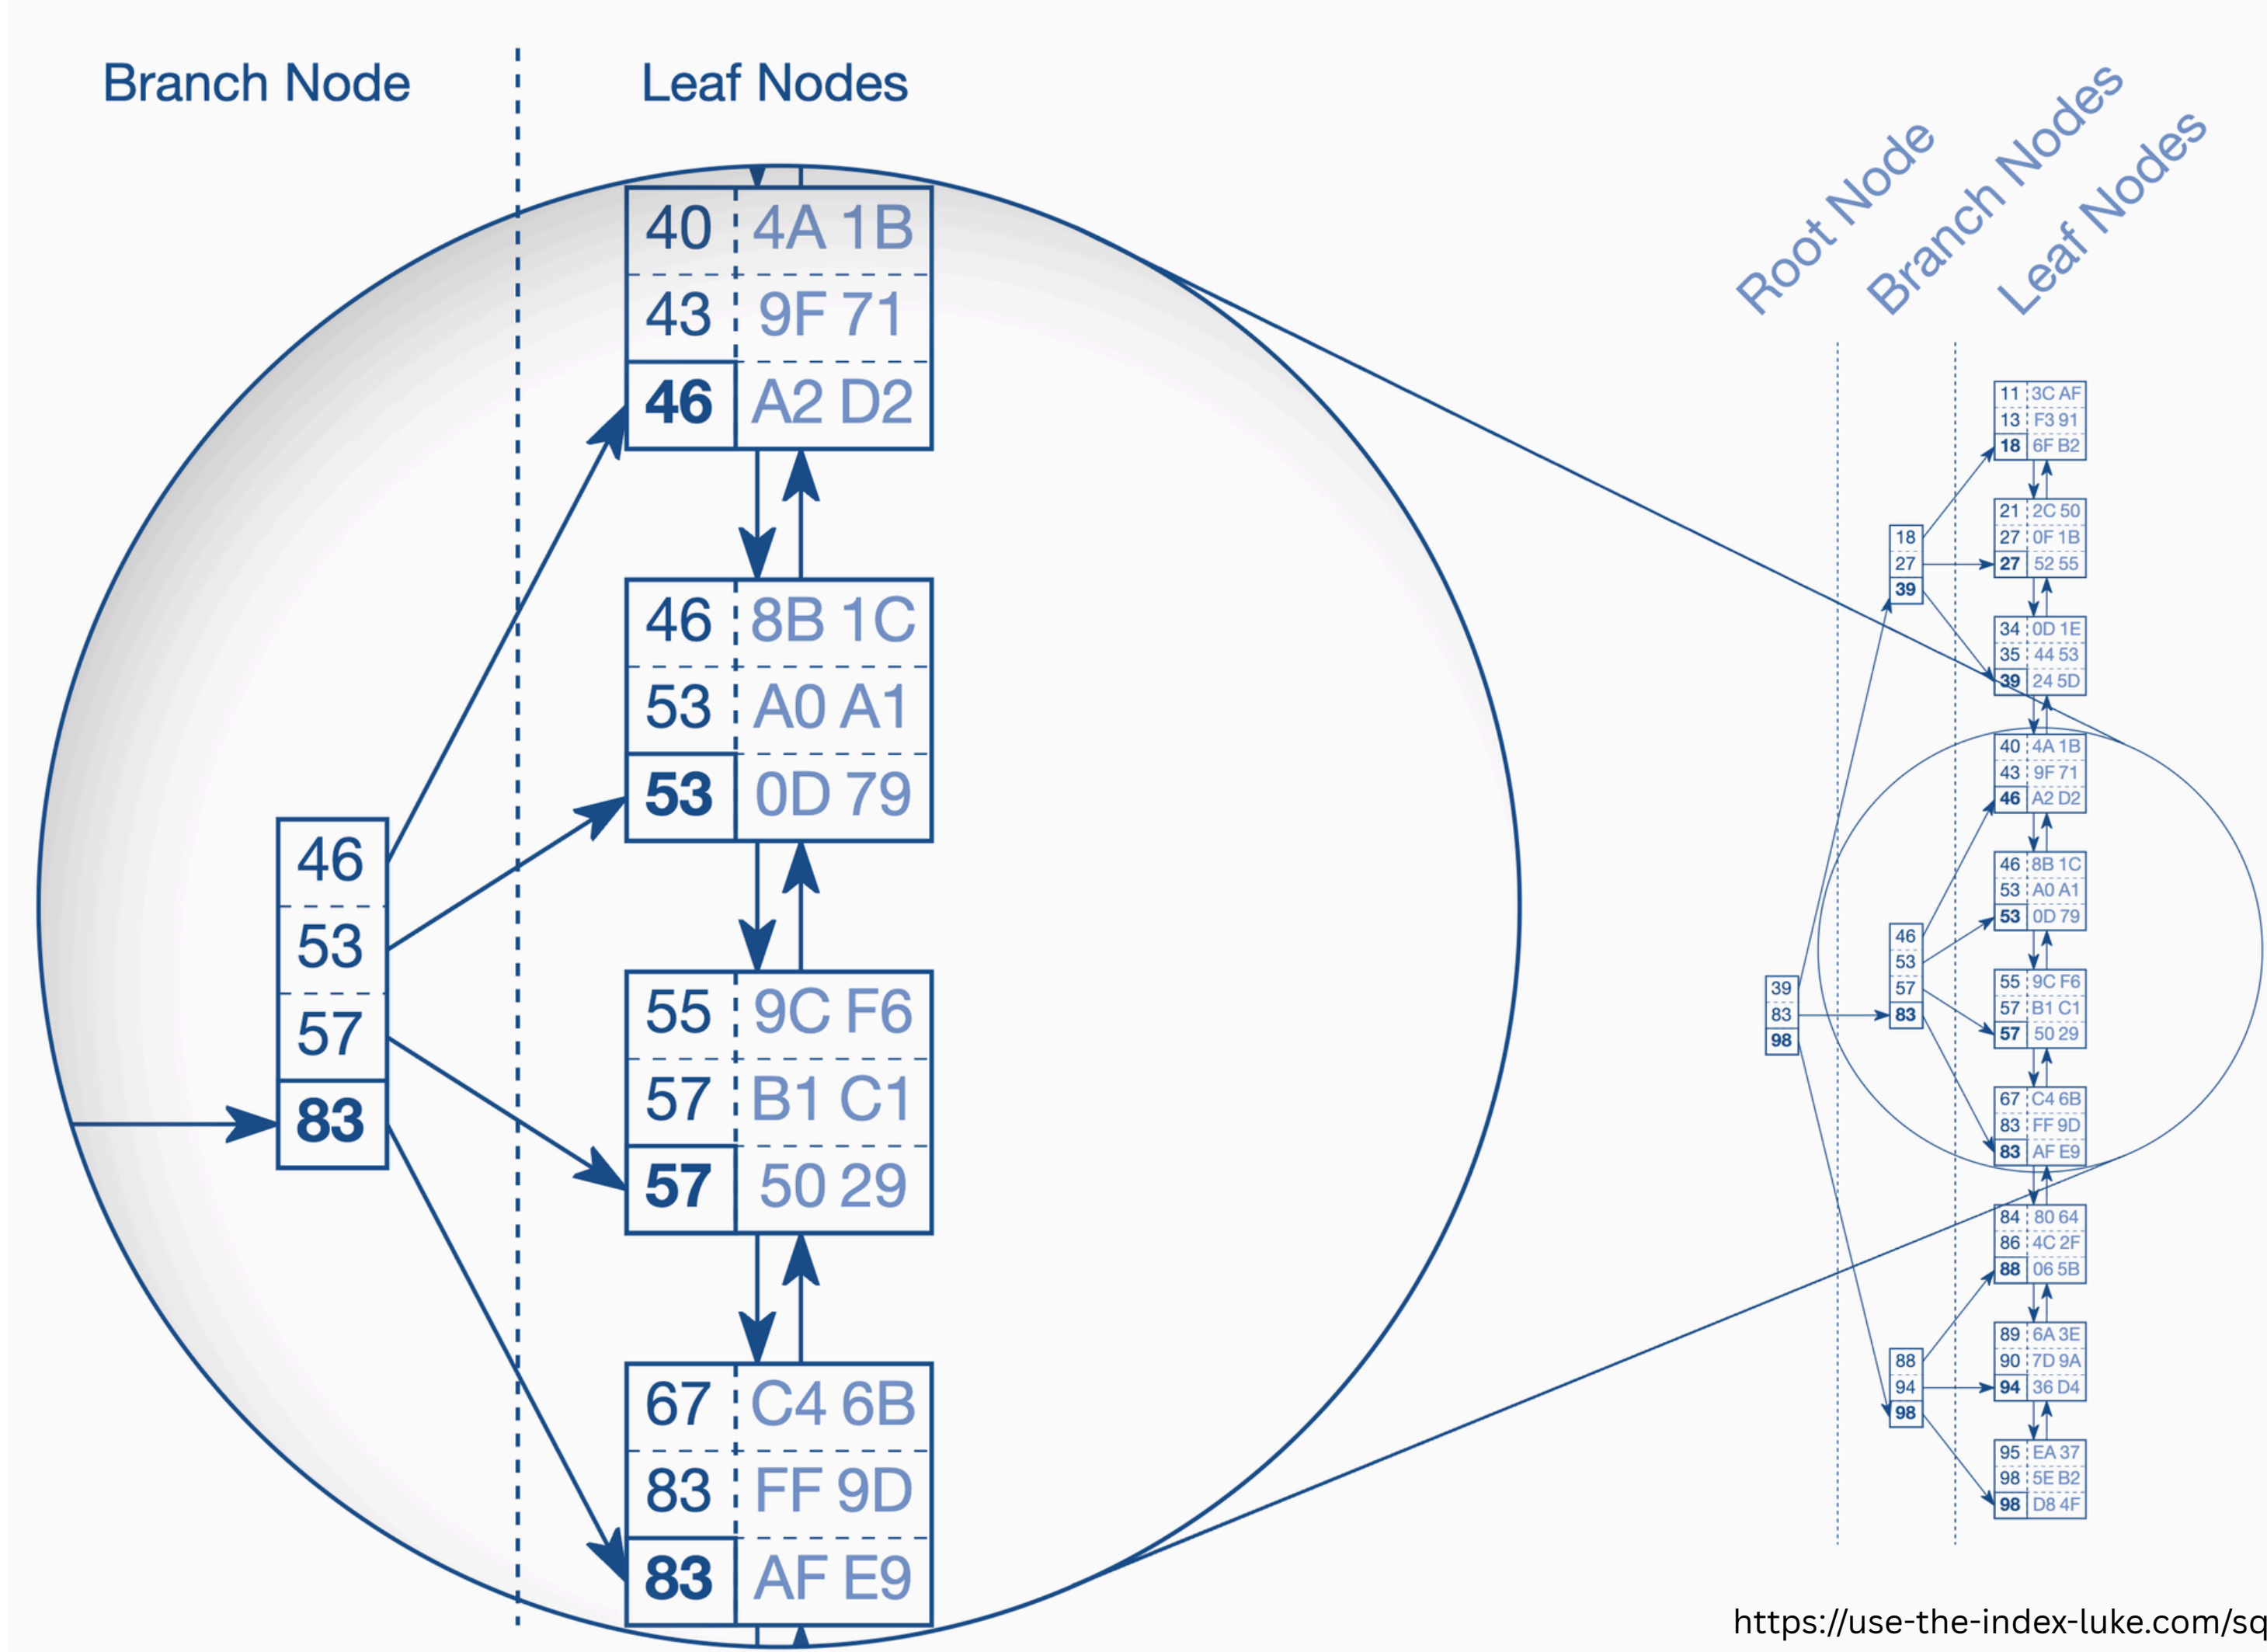
A	39	2	5
X	21	7	2


A	11	1	6
---	----	---	---

A	35	8	3
X	27	3	2

A	18	3	6
A	13	7	4







**Запитання**