

Бази даних

Лекція 14

Тематика лекції

- Pages, Tuples, MVCC
- Організація даних на диску
- Write-Ahead Log (WAL)

Кортеж (tuple)

Кортеж (tuple) - рядок даних таблиці в базі даних.

Кортеж на диску зберігається у наступному форматі:

- метадані - tuple header (23 байта)
- бітмапа NULL значень колонок в даному рядочку
- дані - значення колонок в поточному рядочку

Кортеж - заголовки

Основні частини заголовку кортежа:

- **xmin, xmax - ід транзакцій, що створили та видалили кортеж**
- **ctid - посилання на місце зберігання кортежу або нової версії даного кортежу**
- **hoff (header offset) - адреса початку даних**
- **infomask - різноманітні пропорці**

MVCC

MVCC (Multi Version Concurrency Control) - механізм, який використовує PostgreSQL для контролю конкурентних транзакцій. За своєю суттю це є Copy-on-Write.

Ідея MVCC полягає в тому, що кожний update - це запис нової версії рядочку. При цьому, транзакції, що почались до моменту update - можуть бачити лише стару версію (repeatable read).

MVCC

При оновленні рядочка створюється нова версія. Дані попередньої версії рядочка не змінюються, проте змінюються заголовки.

v1_tuple.xmax = transaction id

v2_tuple.xmin = transaction id

v2_tuple.xmax = 0

v1_tuple.ctid = v2_tuple


Сторінка (page)

Сторінка - логічна одиниця збереження даних базами даних на диску.

Сторінка - послідовний сектор пам'яті, що містить метадані та кортежі.

Сторінки завжди мають фіксований розмір (8КВ за замовчуванням).

Структура сторінки



Заголовки сторінки



Заголовки мають розмір 24 байти та містять:

- Чек-сума сторінки
- Посилання на початок і кінець вільного місця на сторінці
- Розмір сторінки та версія алгоритму роботи з сторінкою
- Найбільше значення хтак кортежів збережених на даній сторінці

MVCC - hot update

Якщо при оновленні кортежа, нова версія зберігається на тій самі сторінці, що і попередня - оновлення індекса не відбувається, попередня версія просто зберігає посилання на нову версію. Тому це надзвичайно швидкий процес, який вимагає лише одного фізичного запису на диск.

MVCC - NOT update



Збереження сторінок

Сторінки зберігаються на диску у форматі кучі (Heap Files).

Куча (в даному контексті) - це неупорядкований набір сторінок.

Шлях до файлу, що зберігає сторінки:
\$PGDATA/base/{id бази даних}/{id таблиці}

TOAST

Проблема: сторінки завжди мають фіксований розмір - 8КВ.

```
CREATE TABLE test (
    id SERIAL,
    data TEXT
);
```

TOAST

Проблема: сторінки завжди мають фіксований розмір - 8КВ.

```
CREATE TABLE test (
    id SERIAL,
    data TEXT -- може містити значення більше 8КВ
);
```


TOAST


Проблема: сторінки завжди мають фіксований розмір - 8КВ.


Рішення: The Oversized-Attribute Storage Technique (TOAST).

Ідея в тому, щоб великі значення зберігати в окремій таблиці, яка зберігає дані великого розміру, а основна таблиця зберігає лише посилання на великий “шматок” даних.

B-Tree







Збереження B-Tree на диску

B-Tree зберігається у вигляді сторінок по 8КВ.

Кожна вершина дерева відповідає одній сторінці.

Кількість читань з диску для пошуку одного значення по індексу відповідає глибині дерева + 1 читання даних з сторінки таблиці.

Write-Ahead Log (WAL)

WAL - підхід, який використовує PostgreSQL для ефективного збереження транзакцій на диск.

Ідея WAL полягає в тому, що СУБД всі зміни в процесі транзакції записує у сторінки в оперативній пам'яті і також в оперативній пам'яті зберігає історію змін. При комміті транзакції відбувається запис історії змін на диск, а запис змінених сторінок відбувається пізніше у фоновому режимі.

Write-Ahead Log (WAL)

Основні принципи:

- Лог змін записується перш за все.
- Комміт транзакції очікує WAL **fsync**.
- Змінені сторінки записуються пізніше асинхронно.
- Періодично відбуваються чекпоінти - запис всіх сторінок з пам'яті на диск.

Write-Ahead Log (WAL)

Переваги WAL:

- Запис логу на диск значно швидший, ніж запис сторінок з даними.
- Тому запис логувідбувається синхронно, а запис сторінок - асинхронно.
- Якщо WAL записаний, а сторінки ні і стається збій - з логу можна відновити оригінальні дані.

Висновки

- Все зберігається у форматі сторінок
- Сторінки завжди фіксованого розміру
- I/O операції з диском завжди по 8КВ
- Дані таблиць зберігаються в рандомному порядку
- Всі рядочки на диску незмінні

Питання